

Ciencia de Datos y Machine Learning

Parte 3: **Clasificación**

Israel N. Chaparro-Cruz

MTI102: Ciencia de Datos y Machine Learning

Naturaleza: Teórica-práctica

Área de Formación: Especializada


La **naturaleza** es teórico-práctico, de carácter **obligatorio**.

La asignatura comprende: **Fases de la Ciencia de Datos**.

Fases para el desarrollo de machine learning. Python y sus herramientas para ciencia de datos. Ingesta de datos. Exploración de datos con la estadística descriptiva y visualización. Preparación de los Datos para Machine Learning. Selección de características de los datos para Machine Learning. Algoritmos de clasificación, regresión y clustering con Machine Learning. Evaluación del desempeño de los algoritmos de machine learning. Despliegue.


Aprendizaje Supervisado

Regresión: predecir valores. **Clasificación:** predecir clases.




Regression

versus



Classification


MNIST




MNIST

https://www.youtube.com/watch?v=FwFduRA_L6Q


Regresión Logística entrenado con SGD



Dummy Classifier



Dummy Classifier (la clase más común)



Accuracy
Exactitud=

#aciertos/total


99M/100M

0.99

Exactitud es 99%

Cross Validation

CROSS VALIDATION, EXPLAINED



Accuracy o ~~precisión~~ exactitud

<https://developers.google.com/machine-learning/crash-course/classification/accuracy-precision-recall>


$$\text{Accuracy} = \frac{\text{correct classifications}}{\text{total classifications}} = \frac{TP + TN}{TP + TN + FP + FN}$$

~~$$\text{Precision} = \frac{\text{correctly classified actual positives}}{\text{everything classified as positive}} = \frac{TP}{TP + FP}$$~~

Tipos de errores



Clasificación Binaria



Clasificación Binaria

+ 1 ←


- 0

modelo

real

real=1
modelo=1
TP

real=1
modelo=0
FN



real=0
modelo=0
TN

real=0
modelo=1
FP

FP

¿TP? ¿FP? ¿TN? ¿FN?

—————
¿CORRECTO? MODELO

T/F

P/N

TRUE POSITIVE

TRUE NEGATIVE

FALSE POSITIVE

FALSE NEGATIVE

Matriz de Confusión

[T/F] : [correcto/incorrecto]
(el modelo)

[P/N] : [salida del modelo]

		Actual Values	
		Positive (1)	Negative (0)
Predicted Values	Positive (1)	TP	FP
	Negative (0)	FN	TN

Precision

La **precisión** es la proporción de todas las **clasificaciones positivas** del modelo que **realmente son positivas**. ¿Qué tanto puedo confiar en el **modelo** cuándo nos dice que es positivo?

Se define matemáticamente de la siguiente manera:

$$\text{Precision} = \frac{\text{correctly classified actual positives}}{\text{everything classified as positive}} = \frac{TP}{TP + FP}$$

Recall

Recuperación o tasa de verdaderos positivos La tasa de **verdaderos positivos** (TPR), o la proporción de todos los **positivos reales** que se clasificaron **correctamente como positivos**. ¿Qué tan confiable es haber clasificado correctamente los **positivos**?

Matemáticamente, la recuperación se define de la siguiente manera:


$$\text{Recall (or TPR)} = \frac{\text{correctly classified actual positives}}{\text{all actual positives}} = \frac{TP}{TP + FN}$$

Laboratorio

Calcular el accuracy, precision y recall para el dummy classifier.

Confusion Matrix para DummyClassifier

True label	Predicted label	
	0	1
0	54579	0
1	5421	0



Media aritmética y media armónica

$$\text{Media aritmética} = \frac{a + b}{2}$$

$$\text{Media armónica} = \frac{2ab}{a + b}$$

F1-Score

La puntuación F1 es la media **armónica** (un tipo de promedio) de la precisión y la recuperación.


Matemáticamente, se calcula mediante la siguiente fórmula:

$$F1 = 2 * \frac{\text{precision} * \text{recall}}{\text{precision} + \text{recall}} = \frac{2TP}{2TP + FP + FN}$$

Compensación precision/recall

<https://developers.google.com/machine-learning/crash-course/classification/accuracy-precision-recall>

Fijémonos cómo funciona el SGDClassifier. Calcula una puntuación de 0 a 1 (usando la función logística). Y aplica un umbral para decidir a qué clase pertenece.



Compensación precisión/recall

$$\text{Precision} = \frac{VP}{VP + FP}$$

$$\text{Recall} = \frac{VP}{VP + FN}$$

El umbral cambia la cantidad de FP y FN al aumentar/disminuir la cantidad de positivos y negativos. Por lo tanto, aparece el trade-off o compensación.

Precision vs Recall

Prioriza **precision** cuando los **falsos positivos** son muy costosos o peligrosos.

Preguntas guía: ¿Qué pasa si clasifico algo como positivo y no lo es?

Ejemplos:

- Filtro de spam.
- Diagnóstico de crimen con IA.
- Detección de fraude financiero automático.

Precision vs Recall


Prioriza **recall** cuando los **falsos negativos** son más peligrosos o inaceptables.

Preguntas guía: ¿Qué pasa si dejo de detectar un caso positivo?

Ejemplos:

- Detección de cáncer en estudios médicos.
- Detección de amenazas de seguridad informática.
- Sistemas de emergencia o alerta temprana (tsunamis, incendios).


Compensación precisión/recall



Clasificación MultiClase

Mientras que los clasificadores binarios sólo distinguen entre 2 clases, los clasificadores multiclase (o multinomiales) pueden distinguir entre más de dos clases.

Matriz de Confusión Multiclase



El accuracy (exactitud) es la suma de los valores en la diagonal (todos los TP) sobre TODA la matriz.

Matriz de Confusión Multiclase

		<i>gold labels</i>			
		urgent	normal	spam	
<i>system output</i>	urgent	8	10	1	$\text{precision}_u = \frac{8}{8+10+1}$
	normal	5	60	50	$\text{precision}_n = \frac{60}{5+60+50}$
	spam	3	30	200	$\text{precision}_s = \frac{200}{3+30+200}$
		$\text{recall}_u = \frac{8}{8+5+3}$	$\text{recall}_n = \frac{60}{10+60+30}$	$\text{recall}_s = \frac{200}{1+50+200}$	

Laboratorio

https://colab.research.google.com/drive/1PfhsrufmIObO-6M3yT_BBItowTnjpi6L?usp=sharing